

Работа состоит из четырех заданий.

Задание 1.

Полезные на практике функции и методы pandas

- a) с использованием соответствующей функции считайте содержимое файла “megaGymDataset.csv”. Здесь содержится информация о различных упражнениях, выполняемых в тренажерном зале
- b) с помощью метода `nlargest` получите 5 строк таблицы, где содержится информация об упражнениях с максимальным значением в столбце “Rating”
- c) с помощью метода `nsmallest` получите 3 строки таблицы, где содержится информация об упражнениях с минимальным значением в столбце “Rating”
- d) с помощью метода `query` получите строки таблицы, где содержится информация об упражнениях со значением “Cable” в столбце “Equipment”
- e) с помощью метода `query` получите строки таблицы, где содержится информация об упражнениях, имеющих значение “Cardio” в столбце “Type” и “Beginner” в столбце “Level”
- f) с помощью метода `unique` получите все уникальные значения в столбце “Type”.

Задание 2.

Полезные на практике функции и методы pandas

- a) с использованием соответствующей функции считайте содержимое файла “sleep_health_lifestyle_dataset.csv”. Здесь содержится информация о качестве сна большой группы людей
- b) с использованием методов `uplicated` и `sum`, проверьте есть ли в данной таблице строки-дубликаты
- c) создайте простой список со строковыми элементами “Underweight” и “Normal”, затем с использованием метода `isin` и атрибута `loc` получите только те строки таблицы, где содержится информация о людях, для которых в столбце “BMI Category” указан один из элементов созданного списка, а в столбце “Occupation” – значение “Student”. Сколько строк, соответствующих этому условию, вы получили? (подсказка: если строк, соответствующих условию, не найдено, попробуйте заключить условия внутри `loc` в круглые скобки)
- d) с использованием функции `cut`, создайте новый столбец “Sleep_duration_str”, где выделите 3 категории: `insufficient` (недостаточный), `adequate` (адекватный) и `excessive` (избыточный) в зависимости от значений столбца “Sleep Duration (hours)”

- e) с использованием функции `qcut`, создайте новый столбец “Sleep_quality_str”, где выделите 3 категории: low (низкое качество), medium (среднее) и high (высокое качество) в зависимости от значений столбца “Quality of Sleep (scale: 1-10)”
- f) с использованием метода `map` закодируйте все значения столбца “BMI Category” целыми числами, создав новый столбец “BMI_num”
- g) с использованием функции `get_dummies` выполните бинаризацию значений столбца “Occupation” с параметрами `drop_first = True` и `dtype = 'int64'`
- h) с использованием метода `plot` постройте гистограмму распределения значений в столбце “Quality of Sleep (scale: 1-10)”, определив количество столбцов, равное 15.

Задание 3.

Функции и методы `pandas` для изменения формы представления данных

- a) с использованием соответствующей функции считайте содержимое файла “lowest_ranked_movies_data.csv”
- b) с использованием методов `isna` и `sum`, получите количество пропусков по каждому из столбцов таблицы
- c) с использованием методов `uplicated` и `sum`, проверьте есть ли в данной таблице строки-дубликаты
- d) импортируйте модуль `ast`, затем содержимое столбца “stars” исходной таблицы перезапишите результатом использования метода `apply` с функцией `literal_eval` модуля `ast`
- e) используйте метод `explode` для преобразования исходной таблицы в новую форму: каждый список с именами главных актеров фильмов (столбец “stars”) нужно преобразовать в отдельные строки таблицы с именем каждого из актеров в отдельной строке, результат сохраните в отдельную переменную (подсказка: на вход методу `explode` укажите название столбца “stars”)
- f) получите имена 10 актеров, которые наиболее часто снимались в фильмах с самым низким рейтингом (подсказка: используйте метод `value_counts` для таблицы, полученной в предыдущем пункте).

Задача 4.

Сводные и кросс-таблицы

- a) с использованием соответствующей функции считайте содержимое файла “sleep_health_lifestyle_dataset.csv”
- b) с использованием функции `pivot_table` получите сводную таблицу, отражающую среднюю продолжительность сна в разрезе пола человека и типа его занятости (подсказка: в параметре `values` определите название столбца “Sleep Duration (hours)”, а в параметрах `index` и `columns` – названия столбцов “Gender” и “Occupation” соответственно)
- c) с использованием функции `crosstab` получите кросс-таблицу, в строках которой указан пол человека, а в столбцах – тип его занятости (подсказка: в параметре `index` укажите `df.Gender`, а в параметре `columns` – `df.Occupation`)
- d) с использованием функции `pivot_table` получите сводную таблицу, отражающую минимальное количество шагов в день в разрезе категорий по индексу массы тела и полу человека (подсказка: в параметре `values` определите название столбца “Daily Steps”, в параметрах `index` и `columns` – названия столбцов “BMI Category” и “Gender” соответственно, а в параметре `aggfunc` – строковое название функции `min`)